

Rapport d'Évaluation : Modélisation Prédictive

Architecture Pipeline End-to-End sur le Dataset Titanic

Asmaa Naib

Mai 2026

Filière : Ingénierie IA & Data (4ème Année)
Institution : École Marocaine des Sciences de l'Ingénieur (EMSI)
Livrable : Notebook Source (ED.ipynb)
Statut technique : Validé sans erreur (Kernel stable)

1 Introduction et Objectifs du Projet

Ce travail académique s'inscrit dans le cadre de l'évaluation technique des compétences en manipulation de données complexes et en apprentissage supervisé. L'objectif fondamental réside dans la modélisation rigoureuse de la probabilité de survie des passagers du naufrage du Titanic.

Le défi central de cette étude repose sur l'adoption absolue des bonnes pratiques de l'ingénierie des données : l'isolation stricte des phases d'apprentissage pour éliminer toute fuite d'information indirecte (*Data Leakage*), et la construction d'une structure logicielle pérenne via des objets de transformation modulaires.

2 Stratégie de Partitionnement des Données

Afin de prémunir les estimateurs contre tout biais de sur-apprentissage ou d'optimisme artificiel lors de l'imputation statistique, un cloisonnement étanche a été opéré à l'origine du traitement. Les variables purement identifiantes dépourvues de substance prédictive (*PassengerId*, *Name*, et *Ticket*) ont été préalablement éliminées.

Le sous-ensemble des variables caractéristiques X (réduit à 8 colonnes stratégiques) et le vecteur cible y ont été partitionnés en utilisant une approche stratifiée :

- **Ensemble d'entraînement (Train Set)** : Contient 712 lignes (représentant 80% de la matrice) dédiées exclusivement à l'ajustement des paramètres mathématiques et des transformations.
- **Ensemble de validation (Test Set)** : Contient 179 lignes (soit 20% de l'échantillon global) préservées vierges de tout contact algorithmique pour la notation finale.

3 Architecture du Pipeline et Traitement Différencié

En exploitant l'API de Scikit-Learn, un formalisme basé sur le concept de *Column Transformer* a été développé, permettant l'application en parallèle de traitements mathématiques découplés

selon le type inhérent des données :

3.1 Sous-pipeline Numérique (Variables : Pclass, Age, SibSp, Parch, Fare)

- Les données numériques ont subi une imputation univariée via la **valeur médiane locale**, calculée sur le seul ensemble d'entraînement, assurant une bonne résilience vis-à-vis des valeurs aberrantes de la colonne *Fare*.
- Suite à cela, un recentrage et une réduction d'échelle ont été appliqués à l'aide d'un opérateur de standardisation, forçant chaque composante à adopter une moyenne $\mu = 0$ et une variance $\sigma^2 = 1$.

3.2 Sous-pipeline Catégoriel (Variables : Sex, Cabin, Embarked)

- Une imputation par la **modalité la plus fréquente (mode)** a été ordonnée pour combler les valeurs manquantes sans dénaturer la sémantique de l'information.
- Les vecteurs nominaux résultants ont été projetés dans un espace vectoriel binaire à l'aide d'un encodage One-Hot (*OneHotEncoder*).
- L'option de gestion des modalités inconnues a été paramétrée pour ignorer dynamiquement toute entrée inédite survenant au cours de la phase de test, protégeant le système contre les exceptions d'exécution.

4 Modélisation Linéaire et Métriques de Performance

Conformément à la feuille de route visant la robustesse et la sobriété algorithmique, le modèle de **Régression Logistique** a été retenu et encapsulé à la suite du processeur géométrique. Après convergence de la fonction de coût, les résultats sur l'échantillon indépendant de test indiquent une excellente capacité prédictive avec une **exactitude globale (Accuracy Score) de 82.12%**.

Le comportement détaillé de l'estimateur est formalisé à travers le tableau récapitulatif ci-dessous :

TABLE 1 – Mesures d'évaluation du modèle de Régression Logistique

Classe Prédite (Statut)	Précision	Rappel	Score F1	Support Échantillon
Classe 0 (Non-Survivants)	0.84	0.88	0.86	110 passagers
Classe 1 (Survivants)	0.79	0.72	0.76	69 passagers
Moyenne Pondérée	0.82	0.82	0.82	179 passagers

L'analyse croisée démontre que le modèle offre une excellente fiabilité sur la prédiction de la classe majoritaire (non-survie) avec un score F1 culminant à 0.86[cite : 45]. Pour les survivants, la précision se maintient à un niveau tout à fait robuste de 79%, minimisant le taux de faux positifs.

5 Conclusion

En conclusion, l'intégralité des contraintes de l'étude a été satisfaite de manière rigoureuse. L'implémentation logicielle au sein de l'environnement Jupyter a démontré qu'en dépit des contraintes

initiales d’affichage machine, le recours à un formalisme de pipeline strict préserve à la fois l’intégrité scientifique des métriques et la propreté du code source, jetant les bases solides d’une méthodologie d’analyse transférable à des problématiques de plus grande envergure.