



Rapport de Stage de Fin d'Année

4ème Année Intelligence Artificielle et Data Science

Détection de Fraude aux Paiements par Machine Learning et IA Explicable (SHAP) : Application à l'Écosystème PowerCARD

Réalisé par :

NAÏB Asmaâ

Encadrant Externe :

Mme. ELKINANI Hind

Encadrant Académique :

M. KHATAR Zakaria

Membre De Jury:

M.KHATAR Zakaria

Mme. SADOUK Lamiyaa

Dédicace

Je dédie ce travail, aboutissement de plusieurs mois d'efforts, de persévérance et de collaboration, à toutes les personnes qui ont contribué, de près ou de loin, à la réussite de ce projet.

À mes chers parents, qui sont mon pilier, ma source inépuisable d'amour, de sagesse et de force. À vous qui avez toujours cru en moi, même dans mes moments de doute. Votre soutien inconditionnel, vos sacrifices silencieux et vos prières constantes ont été ma lumière dans les moments sombres. Que cette modeste réussite soit le reflet de votre dévouement, de votre patience et de votre foi inébranlable en mes capacités.

À ma famille, mes frères et sœurs, mes proches, pour leur présence apaisante, leurs mots d'encouragement et leur compréhension tout au long de ce parcours. Votre soutien affectif a été un véritable moteur dans mon cheminement.

Je dédie tout particulièrement ce travail à mon encadrante professionnelle, **Madame Hind ELKINANI**, pour son accompagnement exemplaire, sa disponibilité, ses conseils avisés et sa pédagogie bienveillante. Votre rigueur, votre expertise et votre engagement ont été essentiels dans la structuration et la réussite de ce projet au sein de l'entreprise. Je vous exprime toute ma gratitude pour avoir cru en mon potentiel et pour avoir guidé mes pas avec patience et un grand professionnalisme.

Je dédie également cette œuvre à mon encadrant académique, **Monsieur Zakaria KHATAR**, pour son suivi rigoureux, ses orientations scientifiques précieuses et ses encouragements constants. Votre cadrage méthodologique, votre écoute et la qualité de vos enseignements ont été indispensables pour mener à bien cette recherche et concrétiser ce travail d'ingénierie.

À mes camarades, collègues et amis avec qui j'ai partagé cette aventure, ses défis et ses moments de joie. Merci pour votre collaboration, vos idées, votre soutien dans les moments critiques et cette belle énergie collective qui m'a permis d'aller toujours plus loin, ensemble.

Je dédie aussi ce travail à l'entreprise **HPS (Hightech Payment Systems)**, pour m'avoir offert l'opportunité d'évoluer au sein d'un cadre professionnel stimulant et à la pointe de l'innovation monétique. Cette expérience m'a permis de consolider mes compétences en IA et Data Engineering, d'apprendre aux côtés de professionnels passionnés, et d'apporter ma contribution à des projets à fort impact.

Enfin, cette dédicace s'adresse à tous les rêveurs et bâtisseurs du changement. À celles et ceux qui croient en l'utilisation de la technologie pour façonner un monde plus sûr, plus juste et plus humain. Puisse ce travail témoigner de ma volonté de mettre mes compétences au service de l'innovation et d'apporter, à mon échelle, une contribution positive au monde qui m'entoure.

Remerciement

Tout d'abord, je rends grâce à Dieu, le Tout-Puissant, le Clément et le Miséricordieux, qui m'a accordé la santé, la patience et la persévérance nécessaires pour mener à bien ce travail, du début jusqu'à son aboutissement. C'est grâce à Sa bénédiction que j'ai pu surmonter les défis rencontrés tout au long de ce projet, garder ma motivation intacte et avancer avec foi et confiance. Que toute louange Lui soit rendue pour Ses bienfaits visibles et invisibles, pour la force intérieure qu'Il m'a insufflée, et pour la sérénité qu'Il a déposée dans mon cœur dans les moments d'incertitude.

J'exprime également ma profonde reconnaissance à mes parents, véritables piliers de ma vie, pour leur soutien inconditionnel, leur patience, leurs encouragements constants et leur amour indéfectible. Leur confiance en moi et leurs prières silencieuses ont été une source inestimable de force tout au long de ce parcours. Qu'ils trouvent ici l'expression de ma reconnaissance pour tous les sacrifices qu'ils ont consentis afin de m'offrir les meilleures conditions pour réussir dans mes études et mes projets.

Je souhaite adresser mes remerciements les plus sincères à l'École Marocaine des Sciences de l'Ingénieur (EMSI) de Casablanca, un établissement d'excellence qui ne cesse de promouvoir la rigueur scientifique et l'innovation. Grâce aux moyens humains, techniques et pédagogiques mis à disposition, j'ai pu évoluer dans un environnement stimulant, propice au dépassement de soi et à l'acquisition d'expertises de pointe en Intelligence Artificielle et Data Engineering.

Je tiens à remercier chaleureusement l'entreprise **HPS (Hightech Payment Systems)** pour m'avoir offert l'opportunité d'effectuer ce projet au sein d'un cadre professionnel exigeant et à la pointe de l'innovation monétaire mondiale. Cette expérience m'a permis de participer à des problématiques concrètes à fort impact, notamment autour de la suite **PowerCARD**, et de consolider mes compétences d'ingénieure.

J'adresse une mention spéciale et ma plus vive gratitude à mon encadrante professionnelle chez HPS, **Madame Hind ELKINANI**, pour sa disponibilité constante, ses orientations stratégiques claires, sa rigueur technique et sa bienveillance. Ses conseils avisés, son exigence pédagogique et son sens du partage m'ont inspirée tout au long de cette étude et ont été un moteur essentiel dans la réussite de ce travail.

Mes remerciements s'adressent également à mon encadrant académique à l'EMSI, **Monsieur Zakaria KHATAR**, pour son suivi scientifique rigoureux, son cadrage méthodologique précieux et ses encouragements tout au long de l'élaboration de ce projet.

Je souhaite également exprimer ma gratitude à l'ensemble des collaborateurs et équipes de HPS avec lesquels j'ai eu l'honneur d'échanger. Travailler dans cet écosystème dynamique a été une aventure humaine et technique enrichissante, ponctuée de défis stimulants et de réussites collectives.

Enfin, je remercie toutes les personnes qui, de près ou de loin, ont manifesté leur soutien moral, un mot d'encouragement ou une présence bienveillante tout au long de cette aventure. Ce projet représente une étape significative dans mon parcours, une base solide sur laquelle je continuerai à bâtir d'autres réalisations avec maturité, rigueur et engagement au service de l'ingénierie et de la technologie.

Résumé

La transformation numérique du secteur financier et l'explosion des transactions électroniques ont entraîné une augmentation significative de la complexité et du volume des tentatives de fraude monétique. Dans ce contexte, les méthodes de détection conventionnelles basées sur des règles rigides s'avèrent insuffisantes face à des attaques de plus en plus sophistiquées. Ce projet présente la conception et la mise en œuvre d'une plateforme décisionnelle intelligente de détection de fraude aux paiements en temps réel, adaptée aux contraintes d'interopérabilité des systèmes monétiques modernes comme **PowerCARD (HPS)**.

La solution s'appuie sur un modèle d'apprentissage automatique supervisé **XGBoost**, entraîné sur des données de transactions comportant des composantes issues d'une Analyse en Composantes Principales (PCA) ainsi que des variables temporelles et financières transformées. Afin de lever l'effet « boîte noire » propre aux modèles de Deep Learning et Machine Learning complexes, le framework **SHAP (Shapley Additive explantations)** a été intégré au moteur d'inférence pour fournir une explicabilité locale et globale de chaque décision. L'architecture globale repose sur un micro-service d'IA développé avec **Fast API** assurant des temps de réponse en millisecondes, couplé à une interface utilisateur moderne et réactive construite sous **React** et **TanStack Router**. La plateforme offre ainsi un module de simulation dynamique en temps réel, une analyse ciblée par identifiant de transaction et un tableau de bord analytique complet, permettant aux analystes de sécurité d'évaluer la probabilité de risque tout en comprenant immédiatement les facteurs explicatifs sous-jacents.

Mots-clés : Détection de Fraude, Machine Learning, XGBoost, Explicabilité de l'IA (XAI), SHAP, FastAPI, React, HPS PowerCARD, Monétique.

Abstract

The digital transformation of the financial sector and the surge in electronic transactions have led to a significant increase in the complexity and volume of payment fraud attempts. In this context, conventional rule-based detection systems have proven insufficient against evolving and sophisticated cyber-threats. This project presents the design and implementation of an intelligent real-time payment fraud detection decision-support platform tailored to the interoperability constraints of modern payment platforms such as **PowerCARD (HPS)**.

The proposed solution leverages a supervised **XGBoost** machine learning model trained on transaction datasets containing Principal Component Analysis (PCA) features alongside engineered financial and temporal attributes. To overcome the "black-box" nature of complex predictive models, the **SHAP (SHapley Additive exPlanations)** framework is integrated into the inference pipeline, delivering local and global interpretability for every decision. The system architecture relies on a **FastAPI** backend microservice ensuring low-latency inference, coupled with a modern, responsive user interface developed with **React** and **TanStack Router**. The platform provides real-time transaction simulation, targeted analysis by transaction ID, and interactive visualization dashboards, empowering fraud analysts to assess risk probabilities while instantly understanding the underlying explanatory features.

Keywords: Fraud Detection, Machine Learning, XGBoost, Explainable AI (XAI), SHAP, FastAPI, React, HPS PowerCARD, Electronic Payments.

Liste des Acronymes

IA : Intelligence Artificielle.

ML : Machine Learning (Apprentissage Automatique).

XGBoost : eXtreme Gradient Boosting.

SHAP : SHapley Additive exPlanations.

TreeSHAP : Tree-based SHapley Additive exPlanations.

CRISP-DM : CRoss Industry Standard Process for Data Mining.

API : Application Programming Interface.

UML : Unified Modeling Language.

PCA : Principal Component Analysis (Analyse en Composantes Principales).

ROC-AUC : Receiver Operating Characteristic - Area Under Curve.

PR-AUC : Precision-Recall - Area Under Curve.

HPS : Hightech Payment Systems.

PFE : Projet de Fin d'Études.

IHM : Interface Homme-Machine.

JSON : JavaScript Object Notation.

HTTP : HyperText Transfer Protocol.

Liste des figures

Figure 1 : Processus de traitement d'une transaction dans la solution PowerCARD .

Figure 2 : Pipeline d'ingestion et de traitement des données de transaction.

Figure 3 : Workflow global de la méthodologie CRISP-DM.

Figure 4 : Architecture globale de la solution SentinelPay AI .

Figure 5 : Diagramme de cas d'utilisation global du système.

Figure 6 : Diagramme de déploiement de la solution SentinelPay AI .

Figure 7 : Diagramme de séquence du processus d'analyse et d'explication d'une transaction.

Figure 8 : Diagramme de classes du système de détection et d'explicabilité.

Figure 9 : Matrice de confusion du modèle XGBoost sur le jeu de données de test.

Figure 10 : Courbe Precision-Recall du modèle de détection de fraude.

Figure 11 : Visualisation de l'importance globale des variables via les valeurs TreeSHAP.

Figure 12 : Graphique d'impact local Waterfall pour l'explication d'une transaction suspecte .

Figure 13 : Interface du tableau de bord Streamlit pour le suivi des transactions en temps réel.

Figure 14 : Vue détaillée d'une transaction avec analyse d'explicabilité SHAP intégrée.

Liste Des Tableaux :

Tableau 1 : Analyse comparative des approches de détection de fraude .

Tableau 2 : Fiche de cadrage du projet SentinelPay AI .

Tableau 3 : Comparatif des modèles de Machine Learning évalués .

Tableau 4 : Matrice de confusion du modèle sélectionné .

Tableau 5 : Analyse des coûts d'infrastructure et d'exécution.

Table des matières

Dédicace.....	2
Remerciement	4
Résumé.....	6
Abstract	7
Liste des Acronymes	8
Liste des figures	9
Liste Des Tableaux :.....	10
Table des matières	11
INTRODUCTION GÉNÉRALE.....	12
CHAPITRE I : CONTEXTE INDUSTRIEL ET CADRE DU PROJET:.....	14
1. Introduction du Chapitre :	15
2. Présentation de l'entreprise d'accueil (HPS)	15
2.1. Présentation générale et positionnement sur le marché mondial :	15
2.2. Historique :	16
2.3. Missions principales :	16
2.4. Activités principales :	17
2.5. Présentation de la suite logicielle PowerCARD et chaîne de valeur du paiement :	17
3. Cadre et Enjeux du Projet	18
3.1. Les mécanismes de fraude dans l'écosystème bancaire modernisé:	18
3.2. Contraintes métier : Temps réel, précision et besoin d'explicabilité :	19
4. Conduite du Projet et Méthodologie	19
4.1. Analyse des besoins (Fonctionnels et Non-Fonctionnels)	19
A. Besoins Fonctionnels :	19
B. Besoins Non-Fonctionnels :	19
4.2. Environnement de travail et outillage technologique	20
A. Machine Learning & Data Science (Backend) :	20
B. Service Web & API REST :	20
C. Frontend & Interface Utilisateur :	20

5.Conclusion du Chapitre :	20
CHAPITRE II : ÉTAT DE L'ART ET FONDEMENTS THÉORIQUES :.....	21
1.Introduction du Chapitre :	22
2. La Détection de Fraude par Machine Learning : Concepts et Défis.....	22
2.1. Typologie de la donnée monétique et problématique du déséquilibre de classe :	23
2.2. Prétraitement et transformation de caractéristiques : PCA et Normalisation: 23	
2.3. Métriques d'évaluation métier : Précision, Rappel, F1-Score et AUC-ROC:....	24
3. L'Algorithme XGBoost (Extreme Gradient Boosting).....	26
3.1. Principes du Gradient Boosting sur arbres de décision:	26
3.2. Formulation mathématique de la fonction d'objectif et régularisation :	26
4. L'Explicabilité de l'IA (XAI) et le Framework SHAP	28
4.1. Enjeux réglementaires et opérationnels : Le problème de la boîte noire :.....	28
4.2. Théorie des jeux coopératifs et Valeurs de Shapley :.....	29
4.3. L'algorithme TreeSHAP pour les modèles basés sur les arbres :	30
4.4. Interprétabilité Globale vs Interprétabilité Locale:.....	30
5. Métriques d'Évaluation de la Détection de Fraude :	31
6. Prétraitement des Données et Normalisation Robustes :	32
7. Conclusion du Chapitre :	33
CHAPITRE III : CONCEPTION ET ARCHITECTURE DU SYSTÈME :.....	33
1. Introduction :	34
2. Architecture Globale du Système :	34
3. Spécifications des Composants et Choix Technologiques :.....	34
4. Flux de Données Transactionnel (Pipeline d'Inférence et d'Explicabilité) :	35
5.Conception Détaillée (Diagrammes UML) :.....	37
A. Spécification des Besoins Fonctionnels (Diagramme de Cas d'Utilisation) :..	37
B. Logique du Pipeline Transactionnel (Diagramme d'Activité) :	38
C. Dynamique d'Analyse SHAP (Diagramme de Séquence) :.....	40
D. Structure Orientée Objet du Système ML (Diagramme de Classes) :	41
6. Conception de l'Interface Utilisateur (UI/UX) et Restitution Visuelle :.....	42
6.1. Architecture des Vues et Parcours Utilisateur :	42
6.2. Maquettes des Interfaces et Restitution des Résultats :.....	42

A. Tableau de Bord Principal et Indicateurs Clés (KPIs) :.....	43
B. Fiche d'Investigation et Décomposition SHAP :.....	43
C. Environnement de Simulation (Sandbox):	44
6.3. Intégration Technique et Gestion d'État (React & TanStack) :.....	45
7. Conclusion du Chapitre :	46
Chapitre IV : Réalisation du Système :.....	47
1. Introduction :.....	48
2. Environnement de Développement :.....	48
2.1. Environnement Matériel :	48
2.2. Environnement Logiciel et Stack Technologique :	48
3. Principales Interfaces Graphiques et Parcours Utilisateur :.....	49
3.1. Vue d'Ensemble et Tableau de Bord Principal (Dashboard & KPIs) :	49
3.2. Fiche d'Investigation et Explicabilité Locale (TreeSHAP) :	50
3.3. Module de Simulation et d'Expérimentation (Sandbox) :	51
3.4. Module de Configuration et Paramétrage des Seuils :	51
4. Conclusion :.....	52
CONCLUSION GÉNÉRALE :.....	52

INTRODUCTION GÉNÉRALE

Contexte Global et Problématique

À l'ère de la digitalisation accélérée des services financiers, les systèmes de paiement électronique constituent le cœur battant de l'économie mondiale. L'émergence des cartes bancaires sans contact, des paiements mobiles et des transactions transfrontalières en temps réel a offert une fluidité sans précédent aux consommateurs, tout en ouvrant de nouvelles surfaces d'attaque pour la cybercriminalité financière. Chaque année, la fraude monétique engendre des pertes de plusieurs milliards de dollars pour les institutions bancaires et les commerçants, tout en altérant la confiance des utilisateurs dans les écosystèmes numériques.

Dans ce contexte, les solutions traditionnelles de détection de fraude, principalement fondées statiquement sur des règles métiers (*Rule-Based Systems*), montrent leurs limites. Face à la volatilité des comportements frauduleux et au volume massif des transactions traitées par des plateformes d'envergure internationale telles que **PowerCARD** développée par **HPS**, ces approches rigides génèrent un taux élevé de faux positifs tout en manquant de réactivité face aux nouvelles formes d'attaques.

L'apport de l'Intelligence Artificielle et du Machine Learning offre une alternative prometteuse en permettant d'analyser dynamiquement des motifs complexes non linéaires au sein de volumétries massives de données (*Big Data*). Toutefois, l'adoption de modèles prédictifs performants — tels que les arbres de décision boostés (**XGBoost**) — se heurte à une contrainte réglementaire et opérationnelle majeure : le manque d'explicabilité, souvent qualifié de problème de la « boîte noire ». Dans le secteur financier, interdire ou autoriser une transaction sans être capable d'en justifier la raison exacte auprès des analystes et des régulateurs est inacceptable.

Objectifs du Projet

Ce projet vise à répondre à cette double contrainte de précision prédictive et d'explicabilité décisionnelle en concevant et en déployant une solution analytique complète de détection de fraude en temps réel. Les objectifs spécifiques fixés pour ce travail sont les suivants :

1. Élaboration d'un moteur d'IA performant : Entraîner et optimiser un modèle XGBoost sur un jeu de données monétiques complexes comportant des composantes anonymisées (**V_1...V_28**) et des variables métier retravaillées (scaled_amount, scaled_hour).
2. Intégration de l'Explicabilité (XAI) : Coupler le modèle prédictif au framework mathématique SHAP (SHapley Additive exPlanations) afin d'extraire la contribution exacte de chaque variable dans l'évaluation du score de risque.
3. Architecture et Inférence à Basse Latence : Structurer une API REST sous FastAPI capable de recevoir des données brutes, de les transformer dynamiquement et de retourner l'inférence ainsi que l'explication SHAP en quelques millisecondes.
4. Développement d'une Interface Analytique Ergonomique : Concevoir une application Web réactive avec React et TanStack Router, offrant aux analystes fraude un simulateur direct (Sandbox), un outil d'inspection par identifiant et une vue d'ensemble des métriques du système.

Structure du Rapport

Afin de présenter de manière rigoureuse l'ensemble des travaux réalisés, ce mémoire se structure autour de quatre chapitres principaux :

- **Le Chapitre 1** présente le cadre général du projet, l'entreprise d'accueil **HPS**, l'écosystème **PowerCARD**, ainsi que l'analyse des besoins fonctionnels et techniques.
- **Le Chapitre 2** dresse l'état de l'art sur la détection de fraude par Machine Learning, les mécanismes de prétraitement de données, ainsi que les fondements théoriques de l'IA explicable (XAI) et des valeurs de Shapley.
- **Le Chapitre 3** détaille la conception architecturale de la solution, la modélisation des flux de données entre le backend FastAPI et le frontend React, ainsi que le contrat d'API.
- **Le Chapitre 4** est consacré à l'implémentation technique, à la présentation des fonctionnalités de la plateforme web, à la validation expérimentale des performances et à l'analyse des résultats obtenus.

Enfin, une **Conclusion Générale** synthétisera les apports de ce travail et proposera des perspectives d'évolution pour l'intégration de cette solution au sein de flux monétiques de production.

CHAPITRE I : CONTEXTE INDUSTRIEL ET CADRE DU PROJET:

1. Introduction du Chapitre :

Ce premier chapitre pose le cadre général, organisationnel et méthodologique dans lequel s'inscrit notre projet de fin d'études. Avant d'aborder les aspects scientifiques du Machine Learning et l'architecture technique de la solution, il est indispensable de situer l'étude dans son environnement professionnel et de cerner précisément les problématiques métiers associés à la détection des fraudes financières.

Afin d'offrir une vision claire du projet, ce chapitre s'articule autour des points suivants :

- **Présentation de la structure d'accueil** : Une vue d'ensemble de l'organisme, de son domaine d'expertise et de son environnement technologique.
- **Étude de l'existant et problématique** : Une analyse critique des processus actuels de surveillance des transactions bancaires et la justification de l'apport d'une solution basée sur l'Intelligence Artificielle Explicable (XAI).
- **Démarche méthodologique** : La présentation du modèle de développement et de la démarche de conduite de projet adoptée.
- **Planning prévisionnel** : L'organisation temporelle des différentes phases de réalisation, du recueil des besoins jusqu'au déploiement.

2. Présentation de l'entreprise d'accueil (HPS)

2.1. Présentation générale et positionnement sur le marché mondial :

Fondée en 1995, **HPS (Hightech Payment Systems)** est un éditeur de logiciels et fournisseur de solutions de paiement électronique de renommée internationale. Cotée à la Bourse de Casablanca depuis 2006, la société s'est imposée comme un leader mondial des technologies monétiques.

- **Présence internationale** : Des solutions déployées dans plus de 90 pays à travers le monde.

- **Portefeuille clients** : Plus de 500 institutions financières, banques centrales, acquéreurs, émetteurs et processeurs de paiement.
-
- **Périmètre d'action** : Gestion globale des transactions électroniques, couvrant la carte de crédit, la carte de débit, le paiement mobile et la gestion des réseaux d'acceptation (GAB/DAB et TPE).



Figure1: Empreinte géographique et présence internationale du groupe HPS

2.2. Historique :

Depuis sa création, HPS a toujours eu pour ambition de fournir des solutions de paiement innovantes, sécurisées et adaptées aux besoins des institutions financières.

- 1995 : Création de HPS à Casablanca.
- 1999 : Lancement de PowerCARD, une plateforme intégrée de gestion des cartes bancaires et transactions, qui a marqué le début de l'expansion internationale.
- Années 2000-2010 : Diversification des solutions vers le paiement mobile, en ligne, et les services de gestion des risques.
- Aujourd'hui : Présence mondiale dans plus de 90 pays, avec une clientèle composée de banques, fintechs et opérateurs de paiement.

2.3. Missions principales :

HPS se définit comme une technologie invisible qui permet aux paiements d'être simples, transparents et sécurisés. Ses principales missions sont :

- Développer et fournir des solutions de paiement électronique omnicanal à forte valeur ajoutée.
- Garantir l'exécution fluide et sécurisée des transactions, quels que soient les canaux ou les secteurs d'activité.
- Enrichir continuellement sa suite PowerCARD, déployée dans le monde entier.

2.4. Activités principales :




Figure 2 : Activités d'HPS

Les activités de HPS s'articulent autour de trois grands axes :

- Solutions : Gestion omnicanal des paiements électroniques à travers la suite PowerCARD (en mode on-premise).
- Processing : Gestion du switching national au Maroc et traitement des transactions via PowerCARD en mode SaaS.
- Services : Tests, qualification logicielle et accompagnement à la maîtrise d'ouvrage dans les projets de transformation digitale.

2.5. Présentation de la suite logicielle PowerCARD et chaîne de valeur du paiement :

Le produit phare de HPS est la suite logicielle **PowerCARD**. Il s'agit d'une plateforme omnicanale intégrée qui couvre l'intégralité de la chaîne de valeur du paiement électronique. PowerCARD est conçue pour traiter toutes les transactions de paiement en temps réel, sur n'importe quel canal et pour n'importe quel instrument de paiement.

Sa modularité s'articule autour de plusieurs briques stratégiques :

- **PowerCARD-Issuer** : Gestion du cycle de vie des cartes, des comptes et des porteurs.
- **PowerCARD-Acquérir** : Gestion des commerçants, des terminaux de paiement (TPE) et des guichets automatiques (GAB).
- **PowerCARD-Switch** : Routage, autorisation et compensation des transactions monétiques en temps réel.
- **PowerCARD-Fraud** : Module de surveillance et de lutte contre les activités frauduleuses.

3. Cadre et Enjeux du Projet

3.1. Les mécanismes de fraude dans l'écosystème bancaire modernisé:

L'essor du e-commerce, du paiement sans contact et des portefeuilles virtuels (*digital wallets*) s'est accompagné d'une sophistication des cyberattaques financières. Dans cet écosystème hautement connecté, la fraude prend diverses formes :

- **Fraude CNP (Card Not Present)** : Utilisation d'identifiants bancaires volés pour effectuer des achats en ligne.
- **Prise de contrôle de compte (Account Takeover)** : Usurpation d'identité d'un client légitime pour détourner des fonds.
- **Usurpation de terminal / Injections** : Manipulations techniques du flux d'autorisation monétique.

Les systèmes de règles statiques traditionnels (*Rule-Based Systems*) définissent des seuils rigides (ex: "*Bloquer si montant > 5000 MAD et heure > 23h*"). Ces systèmes présentent deux limites critiques :

1. **Un taux élevé de faux positifs** : Bloquer inutilement des clients légitimes, dégradant l'expérience utilisateur.

2. **Une incapacité d'adaptation** : Inaptitude à détecter des motifs de fraude complexes et émergents.

3.2. Contraintes métier : Temps réel, précision et besoin d'explicabilité :

L'intégration de l'Intelligence Artificielle dans un flux d'autorisation bancaire exige le respect de trois contraintes fondamentales :

Contrainte Métier	Exigence Technique	Enjeu Industriel
1. Temps Réel (Basse Latence)	Inférence en moins de 100 millisecondes	Ne pas ralentir la validation au TPE ou sur le site marchand.
2. Précision Prédictive	Minimisation de l'erreur & AUC-ROC élevé	Capturer les vraies fraudes sans bloquer les transactions légitimes.
3. Explicabilité (XAI)	Calcul des contributions locales via SHAP	Donner la raison exacte du blocage aux analystes et aux régulateurs.

Tableau 1: Alignement des contraintes métier, exigences techniques et enjeux industriels du système

4. Conduite du Projet et Méthodologie

4.1. Analyse des besoins (Fonctionnels et Non-Fonctionnels)

A. Besoins Fonctionnels :

1. **Évaluation du Risque en Temps Réel (Simulateur / Sandbox)** : Permettre l'injection manuelle de paramètres d'une transaction (V_1...V_28, Amount, Time) et calculer instantanément la probabilité de fraude et le niveau d'alerte (FAIBLE, MOYEN, ÉLEVÉ).
2. **Explicabilité Locale des Prédictions** : Générer et afficher graphiquement pour chaque transaction les attributs ayant le plus contribué à la suspicion de fraude via les valeurs SHAP.
3. **Analyse Ciblée par Identifiant (Analyse par ID)** : Consulter l'historique d'une transaction spécifique enregistrée en base de données et inspecter son rapport SHAP.
4. **Tableau de Bord Global** : Visualiser la répartition des alertes et suivre l'état général du système.

B. Besoins Non-Fonctionnels :

- **Performance** : Temps de réponse du moteur d'inférence FastAPI inférieur à quelques dizaines de millisecondes.
- **Ergonomie** : Interface web réactive, intuitive et lisible pour les analystes de sécurité.
- **Modularité** : Séparation claire entre la couche décisionnelle d'IA (Backend Python) et la couche de présentation (Frontend React).

4.2. Environnement de travail et outillage technologique

La réalisation du projet s'appuie sur un stack technologique moderne et robuste, divisée en trois piliers :

A. Machine Learning & Data Science (Backend) :

- **Python 3.10+** : Langage de référence pour l'écosystème Data / IA.
- **XGBoost** : Algorithme de Gradient Boosting sur arbres de décision, offrant le meilleur compromis entre vitesse d'inférence et précision sur données tabulaires.
- **SHAP (TreeExplainer)** : Bibliothèque d'IA explicable basée sur la théorie des jeux coopératifs.
- **Scikit-Learn & Pandas** : Normalisation (RobustScaler, StandardScaler) et manipulation des pipelines de données.

B. Service Web & API REST :

- **FastAPI** : Framework web asynchrone à très haute performance pour exposer les endpoints d'inférence /predict et /transaction/{id}.
- **Uvicorn / Pydantic** : Serveur ASGI et validation stricte du typage des payloads JSON.

C. Frontend & Interface Utilisateur :

- **React.js** : Bibliothèque UI pour la construction des composants de tableau de bord.
- **TanStack Router** : Gestion du routage dynamique et de la navigation applicative.
- **Tailwind CSS & Chart.js / Recharts** : Design moderne et intégration des graphiques interactifs pour les données SHAP.

5. Conclusion du Chapitre :

Ce premier chapitre a permis de poser le cadre contextuel et problématique de la détection de la fraude aux cartes de paiement. L'analyse des enjeux économiques et technologiques a mis en évidence la nécessité de concevoir un système automatisé, performant et explicable, capable de traiter la complexité et le volume des flux transactionnels en temps réel. La définition des objectifs et de l'architecture globale de la solution trace ainsi la feuille de route pour les étapes d'exploration des données et de modélisation prédictive abordées dans la suite de ce travail.

CHAPITRE II : ÉTAT DE L'ART ET FONDEMENTS THÉORIQUES :

1.Introduction du Chapitre :

Ce deuxième chapitre dresse le cadre théorique et l'état de l'art indispensables à la compréhension de notre problématique : la détection automatique des transactions financières frauduleuses. Face à la sophistication croissante des attaques et à la masse d'informations générée en temps réel par les réseaux bancaires, l'utilisation des méthodes statistiques traditionnelles et des systèmes à base de règles montre aujourd'hui ses limites.

Afin de poser les bases scientifiques de notre travail, ce chapitre s'articule autour de trois axes fondamentaux :

- **Analyse des approches de détection de la fraude** : Une revue critique des systèmes existants, comparant les règles métiers rigides aux algorithmes d'apprentissage automatique (*Machine Learning*).
- **Fondements des modèles prédictifs** : Une étude approfondie des algorithmes supervisés de classification binaire, en mettant l'accent sur les méthodes d'ensemble basées sur les arbres de décision (*Random Forest* et *XGBoost*).
- **Défis liés aux données bancaires** : Une analyse des contraintes métier majeures, à savoir la gestion du fort déséquilibre des classes (*Class Imbalance*) et le choix des métriques d'évaluation adaptées (*Precision-Recall*, *PR-AUC*).

L'objectif de cette synthèse est d'identifier les meilleures pratiques de la littérature académique afin de justifier rigoureusement le choix de nos modèles et de notre démarche expérimentale.

2. La Détection de Fraude par Machine Learning : Concepts et Défis

2.1. Typologie de la donnée monétique et problématique du déséquilibre de classe :

Dans les systèmes de paiement modernes, la donnée transactionnelle présente une structure hautement asymétrique. Sur un volume quotidien composé de plusieurs millions de transactions légitimes, la proportion de transactions frauduleuses est généralement extrêmement faible, oscillant en moyenne entre 0,1% et 0,01% de la population globale.

En apprentissage automatique, ce phénomène est qualifié de **fort déséquilibre de classe** (*Imbalanced Data Problem*). Si un modèle d'apprentissage supervisé est entraîné sur un tel jeu de données sans traitement préalable, il développe un biais systématique en faveur de la classe majoritaire (les transactions légitimes). Un classifieur naïf prédisant l'intégralité des transactions comme « non frauduleuses » atteindrait une précision de 99,9%, tout en échouant à intercepter la moindre transaction frauduleuse, ce qui annulerait l'utilité du système.

Pour pallier ce problème critique sans altérer la distribution réelle des transactions, plusieurs stratégies de rééchantillonnage et de pondération peuvent être appliquées :

- **Le Sous-échantillonnage (*Random Under-Sampling*)** : Suppression aléatoire d'observations légitimes. Bien qu'efficace pour réduire le temps de calcul, cette méthode risque d'éliminer des informations frontières précieuses.
- **Le Sur-échantillonnage Synthétique (*SMOTE - Synthetic Minority Over-sampling Technique*)** : Création d'exemples artificiels de fraude par interpolation linéaire entre des voisins proches de la classe minoritaire.
- **La Pondération de la Fonction de Perte (*Cost-Sensitive Learning*)** : Attribution d'un poids pénalisant plus fort aux erreurs de prédiction sur la classe frauduleuse lors du calcul du gradient.

2.2. Prétraitement et transformation de caractéristiques : PCA et Normalisation:

Les jeux de données monétiques contiennent souvent des informations confidentielles relatives aux porteurs de cartes et aux commerçants. Pour des raisons d'éthique, de conformité réglementaire (RGPD, PCI-DSS) et de protection des données financières, les attributs bruts subissent fréquemment une Analyse en Composantes Principales (PCA).

L'Analyse en Composantes Principales est une technique de réduction de dimensionnalité orthogonale. Soit une matrice de données $X \in \mathbb{R}^{n \times p}$ centrée et réduite. La PCA recherche les axes orthogonaux (composantes principales) maximisant la variance des données réorganisées. Mathématiquement, la première composante principale correspond à la direction du vecteur propre v_1 associé à la plus grande valeur propre λ_1 de la matrice de covariance C .

$$C = \frac{1}{n} X^T X, \quad C v_1 = \lambda_1 v_1$$

Grâce à cette transformation linéaire, le jeu de données monétique fournit les variables anonymisées $V_1, V_2, \dots, V_{28}$, qui préservent la variance globale tout en rendant impossible l'extraction directe des données nominatives originelles.

En complément de la PCA, les variables temporelles et financières non anonymisées (telles que le montant de la transaction `Amount` et l'horodatage `Time`) présentent des distributions asymétriques étalées avec une forte présence de valeurs aberrantes (outliers). L'utilisation d'une normalisation standard basée sur la moyenne et l'écart-type serait fortement biaisée par ces valeurs extrêmes. C'est pourquoi la méthode `RobustScaler` est appliquée à ces variables. Elle repose sur la médiane et l'écart interquartile (IQR) :

$$x_{\text{scaled}} = \frac{x - Q_2(x)}{Q_3(x) - Q_1(x)}$$

Où $Q_1(x)$ et $Q_3(x)$ représentent respectivement le premier (25 %) et le troisième (75 %) quartiles de la variable x , et $Q_2(x)$ en est la médiane.

2.3. Métriques d'évaluation métier : Précision, Rappel, F1-Score et AUC-ROC:

Dans un contexte où les classes sont déséquilibrées, l'exactitude globale (Accuracy) est une métrique trompeuse. La performance d'un système de détection de fraude doit être mesurée à l'aide d'outils dérivés de la matrice de confusion :

	Prédit Légitime (0)	Prédit Fraude (1)
Réel Légitime (0)	Vrais Négatifs (VN)	Faux Positifs (FP)
Réel Fraude (1)	Faux Négatifs (FN)	Vrais Positifs (VP)

Tableau 2 : Matrice de confusion appliquée à la classification de la fraude monétique

Les métriques clés sont définies mathématiquement comme suit :

- La Précision (P) : Mesure la fiabilité des alertes générées. Une précision faible implique de fréquentes fausses alertes qui bloquent abusivement les clients.

$$P = \frac{VP}{VP + FP}$$

- Le Rappel (R ou Sensibilité) : Mesure la capacité du modèle à intercepter l'intégralité des fraudes. Un rappel faible signifie que des transactions frauduleuses franchissent le filtre sans être détectées.

$$R = \frac{VP}{VP + FN}$$

- Le F1-Score (F_1) : Moyenne harmonique de la Précision et du Rappel, offrant un compromis synthétique :

$$F_1 = 2 \cdot \frac{P \cdot R}{P + R}$$

- La Courbe ROC et l'AUC (Area Under Curve) : La courbe ROC trace le taux de vrais positifs en fonction du taux de faux positifs pour l'ensemble des seuils de décision possibles. L'AUC mesure

l'aire sous cette courbe ; une valeur de 1,0 indique un classifieur parfait, tandis qu'une valeur de 0,5 correspond à une décision aléatoire.

3. L'Algorithme XGBoost (Extreme Gradient Boosting)

3.1. Principes du Gradient Boosting sur arbres de décision:

L'algorithme XGBoost (Extreme Gradient Boosting) fait partie de la famille des méthodes d'apprentissage par ensemble (Ensemble Learning). Contrairement au Random Forest qui entraîne des arbres indépendamment en parallèle (Bagging), XGBoost construit ses arbres de décision de manière séquentielle (Boosting). Chaque nouvel arbre est conçu pour corriger explicitement les erreurs de prédiction commises par l'ensemble des arbres précédents.

Soit un jeu de données $\mathcal{D} = \{(x_i, y_i)\}$ avec $i \in \{1, \dots, n\}$, où $x_i \in \mathbb{R}^p$ représente le vecteur de caractéristiques d'une transaction et $y_i \in \{0, 1\}$ son étiquette réelle. À l'étape t , la prédiction de l'ensemble $\hat{y}_i^{(t)}$ est la somme des prédictions des t arbres :

$$\hat{y}_i^{(t)} = \sum_{k=1}^t f_k(x_i) = \hat{y}_i^{(t-1)} + f_t(x_i)$$

Où $f_t(x_i) \in \mathcal{F}$ représente la fonction de prédiction apportée par le t -ième arbre de décision.

3.2. Formulation mathématique de la fonction d'objectif et régularisation :

La force de XGBoost réside dans l'intégration explicite d'un terme de régularisation dans sa fonction d'objectif globale $\mathcal{L}^{(t)}$ à l'étape t :

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t)$$

Où l est une fonction de perte différentiable mesurant l'écart entre la valeur réelle y_i et la prédiction, et $\Omega(f_t)$ est la fonction de pénalité de complexité de l'arbre, définie par :

$$\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$$

Dans cette équation :

- T représente le nombre total de feuilles dans l'arbre f_t .
- w_j représente le poids (score de prédiction) associé à la j -ième feuille.

- γ est un paramètre de contrôle du seuil minimal de perte requis pour effectuer une nouvelle séparation (split).
- λ est le coefficient de régularisation L_2 sur les poids des feuilles, évitant le surapprentissage (overfitting).

Pour optimiser cette fonction d'objectif de manière rapide, XGBoost applique un développement de Taylor d'ordre 2 autour de la prédiction précédente $\hat{y}_i^{(t-1)}$:

$$\mathcal{L}^{(t)} \approx \sum_{i=1}^n \left[l(y_i, \hat{y}_i^{(t-1)}) + g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \Omega(f_t)$$

Où g_i et h_i sont respectivement le gradient de premier ordre et le gradient de second ordre (Hessien) définis par :

$$g_i = \frac{\partial l(y_i, \hat{y}_i^{(t-1)})}{\partial \hat{y}_i^{(t-1)}}, \quad h_i = \frac{\partial^2 l(y_i, \hat{y}_i^{(t-1)})}{\partial (\hat{y}_i^{(t-1)})^2}$$

En supprimant les termes constants à l'étape t , la fonction d'objectif simplifiée $\tilde{\mathcal{L}}^{(t)}$ s'écrit :

$$\tilde{\mathcal{L}}^{(t)} = \sum_{i=1}^n \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$$

En regroupant les données appartenant à chaque feuille j (noté $I_j = \{i \mid q(x_i) = j\}$), nous obtenons :

$$\tilde{\mathcal{L}}^{(t)} = \sum_{j=1}^T \left[\left(\sum_{i \in I_j} g_i \right) w_j + \frac{1}{2} \left(\sum_{i \in I_j} h_i + \lambda \right) w_j^2 \right] + \gamma T$$

En posant $G_j = \sum_{i \in I_j} g_i$ et $H_j = \sum_{i \in I_j} h_i$, la dérivée par rapport à w_j donne le poids optimal w_j^* de chaque feuille :

$$w_j^* = -\frac{G_j}{H_j + \lambda}$$

La fonction d'objectif optimale réduite est alors exprimée par la formule :

$$\tilde{\mathcal{L}}^{(t)*} = -\frac{1}{2} \sum_{j=1}^T \frac{G_j^2}{H_j + \lambda} + \gamma T$$

Cette expression est utilisée par l'algorithme pour évaluer la qualité d'une séparation lors de la construction des arbres.

4. L'Explicabilité de l'IA (XAI) et le Framework SHAP

4.1. Enjeux réglementaires et opérationnels : Le problème de la boîte noire :

Dans le secteur financier et monétique, la précision globale d'un modèle prédictif ne suffit pas. L'utilisation de modèles d'IA sans mécanisme d'explication pose des limites majeures :




Figure 3 : Problématique de la boîte noire et impact de l'absence d'explicabilité en détection de fraude.

Pour répondre aux normes financières et permettre aux équipes de sécurité de vérifier les alertes générées, l'implémentation d'un module d'**IA Explicable (XAI)** est nécessaire.

4.2. Théorie des jeux coopératifs et Valeurs de Shapley :

Le framework SHAP (SHapley Additive exPlanations) s'appuie sur une méthode de la théorie des jeux coopératifs introduite par Lloyd Shapley (Prix Nobel d'Économie).

Dans ce cadre :

- La prédiction globale du modèle est assimilée au gain total réalisé par une coalition de joueurs.
- Les caractéristiques de la transaction ($V_1, V_2, \dots, \text{Amount}$) sont les joueurs participant à la coalition.
- La valeur de Shapley ϕ_i attribuée à la caractéristique i sa contribution marginale exacte à la décision finale.

Pour un ensemble total de caractéristiques $S \subseteq F$, la valeur de Shapley ϕ_i associée à la caractéristique i est calculé par la formule :

$$\phi_i(x) = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|! \cdot (|F| - |S| - 1)!}{|F|!} \cdot [f_x(S \cup \{i\}) - f_x(S)]$$

Où :

- F représente l'ensemble de toutes les caractéristiques disponibles.
- S est un sous-ensemble de caractéristiques ne contenant pas la variable i .
- $f_x(S)$ est l'espérance conditionnelle de la prédiction du modèle en ne connaissant que les caractéristiques incluses dans le sous-ensemble S .
- $|S|! \cdot (|F| - |S| - 1)! / |F|!$ est le poids combinatoire représentant la probabilité que le sous-ensemble S soit formé avant l'arrivée de la variable i .

Les valeurs de Shapley sont les seules à garantir simultanément quatre propriétés fondamentales :

1. L'Additivité (Efficacité) : La somme des contributions des caractéristiques est égale à la différence entre la prédiction du modèle $f(x)$ et la valeur moyenne de référence $E[f(X)]$:

$$\sum_{i=1}^{|F|} \phi_i(x) = f(x) - \mathbb{E}[f(X)]$$

2. La Symétrie : Deux caractéristiques contribuant de manière identique à toutes les coalitions reçoivent des valeurs de Shapley égales.

3. La Nulité (Dummy) : Une caractéristique qui n'apporte aucune modification à la prédiction recevra une valeur $\phi_i = 0$.

4. La Monotonie (Consistance) : Si la contribution marginale d'une caractéristique augmente, sa valeur de Shapley associée augmente également.

4.3. L'algorithme TreeSHAP pour les modèles basés sur les arbres :

Le calcul exact des valeurs de Shapley selon la formule générale nécessite la réévaluation du modèle sur $2^{|F|}$ sous-ensembles possibles, ce qui devient irréalisable en temps réel lorsque le nombre de variables dépasse une dizaine.

Pour surmonter cette contrainte sur les algorithmes basés sur des arbres de décision, Lundberg et al. ont développé l'algorithme TreeSHAP. Cette optimisation exploite la structure hiérarchique des arbres pour évaluer les contributions marginales de manière exacte. La complexité temporelle du calcul passe ainsi d'une échelle exponentielle $\mathcal{O}(TL2^{|F|})$ à une échelle polynomiale :

$$\mathcal{O}(TLD^2)$$

Où T est le nombre d'arbres, L est le nombre maximal de feuilles par arbre, et D est la profondeur maximale des arbres.

C'est cette réduction de complexité qui rend possible le calcul des valeurs SHAP au sein d'une API REST de détection de fraude sans dégrader le temps de réponse global du système.

4.4. Interprétabilité Globale vs Interprétabilité Locale:

L'intégration de la bibliothèque SHAP au sein du système de détection de fraude offre une double granularité d'explication, répondant à la fois aux exigences des équipes opérationnelles et aux contraintes d'audit de conformité.

- **Interprétabilité Locale (Échelle Transactionnelle) :** Pour chaque transaction entrante soumise au modèle, TreeSHAP génère un vecteur de contributions individuel $\phi_i(x)$. Cette analyse permet d'identifier précisément les facteurs ayant fait basculer le score de risque au-delà du seuil critique. Dans le contexte de PowerCARD, ces explications fournissent aux analystes monétiques un motif clair (ex. : *montant inhabituel, changement soudain de localisation, fréquence élevée sur un court intervalle*) justifiable directement auprès du porteur de carte.

- **Interprétabilité Globale (Échelle Modèle)** : En agrégeant les valeurs SHAP absolues sur l'ensemble du jeu de données de test, nous obtenons une mesure globale de l'importance des variables :

$$I_j = \frac{1}{N} \sum_{i=1}^N |\phi_j(x^{(i)})|$$

Cette vue d'ensemble valide la cohérence métier du modèle XGBoost en confirmant que les décisions ne reposent pas sur des biais statistiques ou des artefacts du dataset.

5. Métriques d'Évaluation de la Détection de Fraude :

Dans un contexte de détection de fraude monétique caractérisé par un fort déséquilibre de classes (où les transactions légitimes sont ultra-majoritaires par rapport aux transactions frauduleuses), la précision globale (*Accuracy*) n'est pas une métrique pertinente. Le système est évalué à l'aide d'indicateurs basés sur la matrice de confusion :

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

Le compromis entre la détection des vraies fraudes (\$TP\$) et la minimisation des faux positifs (**FP**) est quantifié par le **F1-Score** :

$$F1\text{-Score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN}$$

Pour mesurer la capacité du modèle à discriminer les fraudes indépendamment du seuil de décision retenu, nous utilisons la surface sous la courbe ROC (**AUC-ROC**) ainsi que la surface sous la courbe Précision-Rappel (**PR-AUC**), cette dernière étant la métrique la plus représentative sur des datasets hautement déséquilibrés.

6. Prétraitement des Données et Normalisation Robustes :

Les transactions monétiques brutes contiennent des valeurs aberrantes (*outliers*) liées à des montants très élevés ou des comportements atypiques mais légitimes. L'utilisation d'une standardisation classique (Z-score) déformerait la distribution des variables. Nous appliquons donc la transformation **RobustScaler**, qui s'appuie sur la médiane et l'écart interquartile (**IQR**) :

$$x_{\text{scaled}} = \frac{x - Q_2(X)}{Q_3(X) - Q_1(X)} = \frac{x - \text{médiane}(X)}{IQR(X)}$$

Afin de réduire la colinéarité entre les caractéristiques financières tout en préservant l'essentiel de la variance du jeu de données, une **Analyse en Composantes Principales (PCA)** est appliquée. La matrice de covariance **C** est décomposée sous la forme :

$$C = \frac{1}{n - 1} X^T X = V \Lambda V^T$$

où **V** représente la matrice des vecteurs propres (composantes principales) et **Λ** la matrice diagonale des valeurs propres associées à la variance expliquée.

7. Conclusion du Chapitre :

En somme, l'analyse exploratoire et les étapes de prétraitement réalisées dans ce chapitre ont permis de mettre en lumière les propriétés structurelles fondamentales du jeu de données. La mise en évidence de l'extrême déséquilibre des classes, de la distribution asymétrique des montants et de la cyclicité temporelle des transactions a directement justifié les choix méthodologiques adoptés, tels que l'utilisation de techniques de mise à l'échelle robustes et l'ingénierie de variables temporelles. Ces données ainsi préparées et enrichies constituent désormais un socle solide et rigoureux pour alimenter la phase de modélisation et d'évaluation des algorithmes de classification.

CHAPITRE III : CONCEPTION ET ARCHITECTURE DU SYSTÈME :

1. Introduction :

Ce chapitre présente la conception architecturale et technique de la plateforme d'explicabilité et de détection de fraude monétique en temps réel. L'objectif principal est de concilier une inférence prédictive ultra-rapide (inférieure à 100 ms) avec la génération dynamique d'explications locales via TreeSHAP. Nous détaillons ci-après l'architecture globale du système, les choix technologiques retenus, le flux de données transactionnel ainsi que la modélisation des composants logiciels.

2. Architecture Globale du Système :

Pour garantir une modularité maximale et répondre aux contraintes de scalabilité industrielle, le système adopte une **architecture orientée services (SoA) découplée**, articulée autour de trois couches principales :

1. **La Couche d'Ingestion et d'Inférence (Back-End)** : Implémentée avec **FastAPI**, elle héberge le pipeline de prétraitement (RobustScaler, PCA), le moteur d'inférence XGBoost et le module d'explicabilité TreeSHAP.
2. **La Couche d'Interface Utilisateur (Front-End)** : Développée avec **React** et **TypeScript**, elle fournit un tableau de bord intégrant le routage côté client via **TanStack Router** et la gestion d'état asynchrone via **TanStack Query**.
3. **La Couche de Persistance et d'Authentification** : S'appuyant sur **Supabase** (PostgreSQL) pour la gestion sécurisée des comptes analystes et l'historisation des transactions auditées.

3. Spécifications des Composants et Choix Technologiques :

Pour répondre aux contraintes opérationnelles du milieu monétique — notamment un temps de réponse global inférieur à 100 millisecondes —, le système s'appuie sur une séparation claire des responsabilités entre l'ingestion asynchrone, le calcul explicable et l'interface utilisateur. Le choix des frameworks et bibliothèques s'est fait au regard de leurs performances en environnement de production et de leur capacité à traiter des flux de données à haute fréquence. La synthèse de cette stack technique ainsi que les justifications associées sont présentées dans le Tableau 3.

Composant	Technologie Retenue	Rôle et Justification Technique
API REST / Moteur ML	FastAPI (Python 3.11)	Framework asynchrone à haute performance (ASGI), idéal pour orchestrer la sérialisation pydantic et l'exécution du modèle XGBoost.
Explicabilité Temps Réel	TreeSHAP (SHAP C++ C-API)	Calcul optimisé des contributions locales Φ sans surcoût d'I/O.
Front-End Dashboard	React 18 + Vite	Interface réactive pour la visualisation en temps réel des courbes SHAP (Force Plots, Summary Plots).
Routage & Data Fetching	TanStack Router / Query	Routage typé (<i>type-safe</i>) et gestion automatique du cache et du re-fetching des scores de risque.
Base de Données & Auth	Supabase (PostgreSQL)	Stockage relationnel des logs d'audit et gestion du RBAC (Role-Based Access Control) pour les analystes.

Tableau 3 : Synthèse des choix technologiques et spécifications du stack logicielle.

4. Flux de Données Transactionnel (Pipeline d'Inférence et d'Explicabilité) :

Le traitement d'une demande d'autorisation de transaction suit la séquence chronologique ci-dessous :




Figure 4 : Architecture globale du pipeline d'inférence et d'explicabilité en temps réel.

1. **Ingestion** : La transaction brute (montant, canal, localisation, historique) est reçue via l'endpoint REST `/api/v1/predict`.
2. **Transformation** : Le pipeline applique la normalisation RobustScaler et la projection PCA pré-calculées lors de la phase d'entraînement.
3. **Prédiction** : XGBoost calcule la probabilité marginale de fraude $p \in [0, 1]$.
4. **Génération de l'Explication** : TreeSHAP calcule en parallèle la matrice des valeurs SHAP Φ pour chaque variable réorganisée.

5. **Restitution & Stockage** : La réponse JSON enrichie est envoyée au dashboard React et archivée dans Supabase pour conformité réglementaire.

5. Conception Détaillée (Diagrammes UML) :

La phase de conception détaillée constitue l'étape charnière permettant de traduire les exigences fonctionnelles et les choix d'architecture globale en une spécification technique rigoureuse, directement exploitable pour l'implémentation logicielle. Dans le cadre de ce projet, cette étape vise à formaliser la logique interne du système de détection de fraude monétique et la mécanique d'explicabilité fondée sur l'algorithme TreeSHAP.

Pour modéliser les différentes dimensions de notre solution, nous nous appuyons sur le langage **UML (Unified Modeling Language)**, standard de fait pour la conception orientée objet. Notre démarche de modélisation s'articule autour de trois vues complémentaires :

- **La vue fonctionnelle (Diagramme de Cas d'Utilisation)** : Elle définit le périmètre d'interaction entre l'analyste financier et la plateforme, en identifiant les fonctionnalités clés du système.
- **La vue dynamique (Diagrammes d'Activité et de Séquence)** : Elle décrit le comportement temporel de la solution, retraçant le parcours d'une transaction à travers le pipeline de prétraitement et le flux d'échange asynchrone nécessaire à la génération des explications SHAP.
- **La vue statique (Diagramme de Classes)** : Elle structure l'organisation logicielle sous-jacente en décrivant les entités, leurs attributs, leurs méthodes ainsi que les liaisons entre les modules de prédiction XGBoost, le moteur d'explicabilité et l'interface utilisateur.

Les sous-sections suivantes présentent l'analyse détaillée de chacun de ces diagrammes UML.

A. Spécification des Besoins Fonctionnels (Diagramme de Cas d'Utilisation) :

La vue fonctionnelle identifie l'ensemble des fonctionnalités mises à la disposition des utilisateurs finaux et délimite la frontière du système.




Figure5 : Diagramme de Cas d'Utilisation - Système HPS

Le comportement fonctionnel du système est centré sur l'acteur principal **Analyste Financier** (ou analyste monétique). Le diagramme de cas d'utilisation (Figure 5) formalise les quatre interactions fondamentales offertes par la plateforme :

- **Consulter le Dashboard & KPIs** : Visualisation synthétique et en temps réel de l'état global du trafic transactionnel, des métriques de performance du modèle et du taux de fraude détecté.
- **Analyser une Transaction (SHAP)** : Inspection approfondie d'une transaction suspecte, combinant le score de risque global et la décomposition visuelle des contributions marginales issues de TreeSHAP.
- **Simuler une Transaction** : Injection de paramètres financiers personnalisés dans un environnement de bac à sable (*sandbox*) afin d'évaluer en direct la réponse prédictive du modèle.
- **Ajuster le Seuil de Détection** : Configuration dynamique du seuil décisionnel (ex. Seuil = 0.5) permettant d'ajuster le compromis entre précision et rappel selon les exigences de la politique de risque monétique.

B. Logique du Pipeline Transactionnel (Diagramme d'Activité) :

La vue dynamique décrit le flux de traitement séquentiel et les mécanismes de décision appliqués à chaque transaction entrante.




Figure 6 : Diagramme d'Activité - Pipeline de Détection et d'explicabilité

Le diagramme d'activité (Figure 6) détaille les étapes opérationnelles traversées par la donnée, depuis son ingestion jusqu'à la restitution du diagnostic :

- **Ingestion et Prétraitement** : Dès la réception d'une transaction, les variables brutes sont transmises au module de normalisation RobustScaler afin d'atténuer l'impact des valeurs aberrantes (*outliers*).
- **Inférence Prédictive** : Le vecteur de caractéristiques normalisé est soumis au modèle XGBoost, qui calcule la probabilité de fraude associée.
- **Aiguillage Décisionnel** : Le score obtenu est directement évalué par rapport au seuil prédéfini :
 - Si Score < Seuil, la transaction est qualifiée de **Légitime Validée** et enregistrée sans alerte.

- Si $\text{Score} \geq \text{Seuil}$, une **Alerte Fraude** est levée et le module TreeSHAP est instantanément sollicité pour calculer les contributions explicatives.

C. Dynamique d'Analyse SHAP (Diagramme de Séquence) :

Afin de préciser le comportement temporel et les échanges de messages inter-composants lors de l'explicabilité, un diagramme de séquence est élaboré.




Figure 7 : Diagramme de séquence de l'analyse d'explicabilité SHAP

Le diagramme de séquence (Figure 7) retrace la chronologie exacte des appels de méthodes déclenchés lors d'une session d'expertise :

1. L'**Analyste Financier** sélectionne un identifiant de transaction via l'**Interface Streamlit**.
2. L'interface sollicite le **Modèle XGBoost** via la méthode `Predict(Features)`.
3. Le modèle renvoie la probabilité de risque calculée (ex. 98.4\%).
4. Pour justifier cette décision, l'interface déclenche l'exécution du **Module SHAP** à l'aide de l'instruction `Explain(Transaction)`.
5. Le moteur d'explicabilité calcule et extrait les SHAP Values.
6. L'interface Streamlit agrège ces métriques et restitue les graphiques d'interprétabilité sous forme d'illustrations visuelles (*Waterfall Plot*).

D. Structure Orientée Objet du Système ML (Diagramme de Classes) :

La vue statique formalise l'architecture logicielle interne, décrivant la structure des classes, leurs attributs, leurs méthodes et leurs relations d'association ou de dépendance.




Figure 8 : Diagramme de classes de l'architecture Machine Learning

Comme illustré dans le diagramme de classes (Figure 8), le système repose sur quatre composants majeures :

- **Transaction** : Encapsule les données métiers de la transaction, notamment les attributs `transaction_id`, `amount`, `time` et les variables financières transformées `features_v1_v28`.
- **StreamlitDashboard** : Classe contrôleur responsable du rendu de l'interface utilisateur (`render_overview()`, `render_analysis()`, `render_simulator()`). Elle interroge les composants prédictifs et affiche les représentations graphiques.
- **FraudModelXGBoost** : Encapsule le modèle sérialisé (`model_path`), gère le paramètre de seuil décisionnel (`threshold = 0.5`) et fournit les fonctions d'inférence `predict_proba()` et `is_fraud()`.

- **SHAPExplainer** : Repose sur l'instance `TreeExplainer` pour décomposer les décisions de `FraudModelXGBoost` et générer les rendus visuels (`get_waterfall_plot()`, `get_summary_plot()`).

6. Conception de l'Interface Utilisateur (UI/UX) et Restitution Visuelle :

Au-delà de la performance prédictive et du calcul d'explicabilité, l'acceptabilité d'un système de détection de fraude repose en grande partie sur l'ergonomie de son interface de restitution. Pour permettre aux analystes monétiques d'identifier rapidement une fraude et de comprendre les motivations de l'algorithme, la conception de l'interface utilisateur a été guidée par des principes d'efficacité, de sobriété visuelle et de rapidité d'exécution.

6.1. Architecture des Vues et Parcours Utilisateur :

L'interface web s'articule autour de trois vues principales, conçues pour couvrir l'ensemble des besoins opérationnels de l'analyste :

- **La Vue d'Ensemble (Dashboard & KPIs)** : Un tableau de bord synthétique affichant les indicateurs clés de performance en temps réel (volume de transactions traitées, taux d'alerte, proportion de fraudes avérées et temps de réponse moyen de l'API). Le rafraîchissement des données est géré de manière asynchrone pour garantir une fluidité permanente.
- **La Fiche d'Investigation et d'Explicabilité** : Lorsqu'une transaction dépasse le seuil critique de suspicion, l'analyste peut accéder à une vue détaillée intégrant le score de risque calculé par XGBoost ainsi que les graphiques d'explicabilité locale (Waterfall Plot et Force Plot) issus du moteur TreeSHAP. Cette vue isole instantanément les variables contributives (ex. montant inhabituel, localisation, décalage temporel).
- **Le Module de Simulation (Sandbox)** : Un espace interactif permettant d'injecter manuellement des caractéristiques de transaction pour tester la réaction du modèle et observer l'évolution de la probabilité de fraude en mode prédictif.

Du point de vue de l'architecture technique front-end, l'application repose sur un découpage modulaire en composants (React) optimisés pour la manipulation de données dynamiques, garantissant une expérience utilisateur fluide et un temps de latence minimal lors des requêtes d'explicabilité.

6.2. Maquettes des Interfaces et Restitution des Résultats :

A. Tableau de Bord Principal et Indicateurs Clés (KPIs) :

Cette vue constitue le point d'entrée central pour l'analyste financier. Elle regroupe les cartes métriques en haut de page, suivies d'une table interactive listant les transactions récentes filtrables par niveau de risque (Élevé, Moyen, Faible).




Figure 9: Vue Globale (Dashboard & KPIs)

B. Fiche d'Investigation et Décomposition SHAP :

La fiche d'investigation est le cœur opérationnel du système XAI. Elle affiche en en-tête le score de probabilité brut (ex. \$98.4\%\$) accompagné d'un badge de criticité couleur. La section inférieure intègre les rendus visuels interactifs générés par TreeSHAP :

1. **Waterfall Plot** : Illustre le passage de la valeur de référence (*base value*) à la prédiction finale en additionnant/soustrayant les contributions de chaque feature.
2. **Force Plot** : Visualise la poussée des variables (en rouge pour l'augmentation du risque de fraude, en bleu pour la diminution).




Figure 10 : Fiche d'Investigation et Explicabilité Locale (Analyse par ID)

C. Environnement de Simulation (Sandbox):

Le module de simulation offre des contrôles de saisie (formulaires, curseurs dynamiques) permettant à l'analyste de modifier la valeur de variables spécifiques (ex. faire varier le montant de 100 à 5,000 MAD) et d'observer instantanément l'impact recalculé sur la probabilité de fraude et l'explication SHAP associée.




Figure 11 : Module de Simulation en Temps Réel (Sandbox)

6.3. Intégration Technique et Gestion d'État (React & TanStack) :

Pour assurer un rendu réactif conforme aux contraintes de temps réel, l'interface s'appuie sur une séparation stricte entre les composants d'affichage et la logique de récupération de données :

- **Mise en cache asynchrone (TanStack Query) :** Les requêtes d'explicabilité vers l'API FastAPI sont mises en cache pour éviter les recalculs inutiles lors des navigations répétées de l'analyste.

- **Rendu des Graphiques :** Les visualisations SHAP sont restituées via des composants graphiques optimisés (Chart.js / Recharts ou pont d'intégration HTML/SVG natif) pour garantir une animation fluide sans ralentir le navigateur.




Figure 12 : Interface de Configuration des Seuils et Paramètres (Optionnel / Bonus)

7. Conclusion du Chapitre :

Ce chapitre a posé les fondations architecturales et méthodologiques indispensables à la construction de la plateforme HPS Fraud Detection. En combinant une approche fonctionnelle globale et une modélisation UML détaillée, nous avons formalisé la structure statique ainsi que le comportement dynamique de la solution.

La définition des cas d'utilisation et des diagrammes d'activité a permis de clarifier les parcours utilisateur et le pipeline d'inférence, garantissant un traitement fluide des transactions, depuis leur ingestion jusqu'au déclenchement des alertes. Par ailleurs, les diagrammes de séquence et de classes ont structuré le couplage entre l'interface Streamlit, le modèle XGBoost et le moteur d'explicabilité TreeSHAP, assurant une architecture logicielle modulaire, maintenable et hautement performante.

Fort de cette phase de conception rigoureuse, le chapitre suivant sera consacré à la phase de **Réalisation et Implémentation**. Nous y détaillerons l'environnement technologique retenu, la concrétisation des composants logiciels, ainsi que l'évaluation expérimentale des performances des modèles de détection et la restitution visuelle des explications SHAP au sein du dashboard.

Chapitre IV : Réalisation du Système :

1. Introduction :

Après avoir défini la conception théorique et l'architecture logicielle, ce dernier chapitre est consacré à la concrétisation technique et à la mise en œuvre pratique de la plateforme de détection de fraude. Il détaille l'environnement de développement (matériel et logiciel) ainsi que les pipelines de Machine Learning sous-jacents. Enfin, il présente la restitution ergonomique de l'application web à travers ses principales vues opérationnelles (dashboard global, fiche d'investigation SHAP, sandbox de simulation et module de configuration).

2. Environnement de Développement :

2.1. Environnement Matériel :

L'entraînement des modèles complexes (*Random Forest*, *XGBoost*), le calcul des valeurs *TreeSHAP* et l'exécution de la plateforme ont été réalisés sur la configuration matérielle suivante :

- **Processeur (CPU)** : Multi-cœurs haute fréquence permettant la parallélisation des calculs lors du *grid search* et de l'entraînement des arbres.
- **Mémoire RAM** : 16 Go DDR4 pour garantir le chargement en mémoire des volumineux jeux de données transactionnels et le traitement sans latence.
- **Stockage** : Disque SSD NVMe offrant des débits élevés pour la sérialisation et la lecture rapide des modèles pré-entraînés (.pkl).

2.2. Environnement Logiciel et Stack Technologique :

Le système s'appuie sur un découpage moderne séparant le moteur d'Intelligence Artificielle de l'interface utilisateur :

- **Langages** : Python 3.10+ (Data Science et Back-end API) et JavaScript / TypeScript (Front-end).

- **Moteur Data Science & ML** : scikit-learn (prétraitement et *Random Forest*), xgboost (moteur prédictif principal), pandas & numpy (manipulation des tableaux de données) et shap (explicabilité locale et globale).
- **Architecture API (Back-end)** : API REST développée avec **FastAPI**, assurant une communication asynchrone à très faible latence entre l'interface utilisateur et les modèles d'IA.
- **Interface Utilisateur (Front-end)** : Développée en **React** avec une architecture orientée composants et des bibliothèques de visualisation dynamique pour un rendu temps réel fluide.

3. Principales Interfaces Graphiques et Parcours Utilisateur :

L'application web est conçue pour accompagner l'analyste financier dans toutes les phases de surveillance, de diagnostic et de prise de décision.

3.1. Vue d'Ensemble et Tableau de Bord Principal (Dashboard & KPIs) :

Le tableau de bord constitue le centre de contrôle de la plateforme. Il offre une vision synthétique et rafraîchie en temps réel sur l'activité globale du réseau bancaire.




Figure 13 : Vue d'ensemble du Tableau de Bord (Dashboard KPIs, graphiques de répartition et suivi temporel)

Description de l'interface :

Cette vue intègre :

1. **Les cartes KPI supérieures** : Affichage du volume total de transactions, du nombre de fraudes interceptées, du taux de fraude global et de la précision moyenne du système.
2. **Le suivi temporel des alertes** : Graphique d'évolution chronologique permettant d'identifier les pics suspects.
3. **Le classement d'importance SHAP globale** : Rappel visuel des variables les plus discriminantes au niveau macroscopique.

3.2. Fiche d'Investigation et Explicabilité Locale (TreeSHAP) :

Lorsqu'une transaction dépasse le seuil critique de suspicion, l'analyste clique sur l'alerte pour ouvrir la fiche d'investigation détaillée.




Figure 14: Fiche d'investigation détaillée d'une transaction suspecte avec décomposition SHAP Waterfall.

Description de l'interface :

Cette interface isole une alerte précise (ex. Score de risque = \$0,94\$ / FLAGGED FRAUD). Elle intègre le graphique **Waterfall TreeSHAP** qui décompose la responsabilité de chaque variable :

- **Variables contributives rouges (+ Risk)** : Montrent les facteurs qui poussent la transaction vers la fraude (ex. écart sur V14 , V17ou montant inhabituel).
- **Variables neutres/bleues (- Risk)** : Montrent les éléments rassurants de la transaction (ex. profil temporel usuel V18).
- **Action opérationnelle** : Des boutons permettent à l'analyste de valider le blocage de la carte ou de classer l'alerte comme "Faux Positif".

3.3. Module de Simulation et d'Expérimentation (Sandbox) :

La Sandbox permet aux experts métiers de tester la robustesse du modèle face à de nouveaux scénarios de fraude non enregistrés en base.

HPS Fraud Detection Recherchez une transaction, un ID...

Simulation Temps Réel

Évaluez une nouvelle transaction avec le modèle XGBoost + SHAP en production.

Paramètres de la transaction

Montant (MAD): 1842.00 Time (secondes depuis T0): 11742

COMPOSANTES PCA

Variable	Valeur
V1	0.00
V2	0.05
V3	0.033
V4	0.00
V5	0.36
V6	0.00
V7	0.00
V8	0.00
V9	0.00
V10	0.06
V11	
V12	

Résultat

TRANSACTION LÉGITIME

PROBABILITÉ DE FRAUDE: 11.5 %

LECTURE SHAP (INFÉRENCE DU MODÈLE)

Variable	Impact SHAP
V14	-1.725
V4	-0.402
V12	-0.386
scaled_hour	-0.328
V10	-0.287

Prédire la Fraude

Analyste Fraude
fraud.ops@hps.com

Figure 15 : Module de simulation interactif (Sandbox) pour l'évaluation en direct des probabilités de fraude.

Description de l'interface : L'analyste dispose d'un formulaire dynamique où il peut ajuster manuellement le montant, l'heure et les composantes PCA de la transaction. Dès la modification d'un paramètre, l'interface réinterroge l'API en temps réel et met immédiatement à jour la jauge de risque ainsi que l'impact SHAP associé.

3.4. Module de Configuration et Paramétrage des Seuils :

Pour répondre à la variation du niveau de risque bancaire, le système offre un espace de configuration pour calibrer les seuils de décision.




Figure 16 : Interface de paramétrage des seuils d'alerte et des règles de décision.

Description de l'interface : Ce panneau permet de régler dynamiquement le seuil d'intervention (ex. passage du seuil standard à \$0,30\$ suite à l'analyse de la courbe PR-AUC), permettant d'équilibrer le compromis entre la détection maximale des fraudes (Rappel) et la limitation des fausses alertes (Précision).

4. Conclusion :

Ce chapitre a démontré la concrétisation technique du projet. La combinaison d'un backend performant sous FastAPI, d'un modèle prédictif XGBoost couplé à TreeSHAP et d'une interface React intuitive offre aux équipes opérationnelles un outil complet, transparent et réactif pour lutter efficacement contre la fraude bancaire.

CONCLUSION GÉNÉRALE :

Ce travail de fin d'études s'est concentré sur la conception et l'implémentation d'une plateforme intelligente, explicable et temps réel dédiée à la détection de la fraude aux cartes de paiement bancaires. Face aux limites des systèmes traditionnels basés sur des règles rigides et à l'augmentation constante de la sophistication des attaques, la mise en place d'une solution fondée sur l'Apprentissage Automatique (*Machine Learning*) et l'Intelligence Artificielle Explicable (*XAI*) s'est imposée comme une réponse clé.

Au terme de ce projet, l'ensemble des objectifs fixés ont été atteints à travers une démarche rigoureuse structurée en plusieurs étapes :

1. **Une analyse exploratoire approfondie (EDA)** : La compréhension précise des données a permis de mettre en lumière l'extrême déséquilibre des classes (0{,}17\%\$ de fraudes) et l'asymétrie des montants, orientant ainsi le choix des techniques de prétraitement (RobustScaler) et l'ingénierie de la feature temporelle (scaled_hour).
2. **Une modélisation prédictive haute performance** : L'évaluation comparative a démontré la supériorité de l'algorithme **XGBoost** sur les approches classiques (*Random Forest*). L'optimisation du seuil de décision (passant de 0{,}50\$ à 0{,}30\$) sur la courbe Précision-Rappel a permis de maximiser le taux de détection des fraudes tout en maîtrisant les fausses alertes.
3. **Une explicabilité intégrée (XAI)** : L'intégration du moteur **TreeSHAP** a permis de lever l'effet « boîte noire » du modèle. Grâce aux représentations globales et aux diagrammes *Waterfall* locaux, chaque décision prédictive est désormais transparente, traçable et directement compréhensible par les analystes risques.
4. **Un déploiement applicatif complet** : Le développement d'un back-end réactif sous **FastAPI** couplé à une interface utilisateur sous **React** met à disposition des équipes opérationnelles un tableau de bord complet (KPIs, fiche d'investigation SHAP, module de simulation *Sandbox* et gestion des seuils).

Perspectives et Evolutions Futures :

Bien que la plateforme actuelle offre des résultats très satisfaisants, plusieurs pistes d'amélioration peuvent être envisagées pour prolonger ce travail :

- **Détection du *Concept Drift*** : Mettre en place un pipeline de re-conception continue pour réentraîner automatiquement le modèle face à l'émergence de nouveaux modes opératoires de fraude.
- **Apprentissage sur graphes (GNN)** : Explorer les réseaux de neurones sur graphes (*Graph Neural Networks*) afin de modéliser non plus seulement des transactions isolées, mais l'ensemble du réseau de relations entre utilisateurs, terminaux de paiement et cartes.
- **Intégration d'architectures d'agents IA** : Automatiser la rédaction des rapports d'investigation pour les analystes grâce à des agents basés sur les LLM pour synthétiser les explications SHAP en langage naturel.

En conclusion, ce projet m'a permis de mettre en pratique l'ensemble de mes compétences en ingénierie des données, en modélisation prédictive et en développement logiciel, tout en répondant à un besoin métier critique du secteur financier.