

Page 1 : Introduction au RAG et Enjeux

Le Retrieval-Augmented Generation (RAG) combine la recherche d'information et la génération de texte par LLM. Cette approche permet de pallier les limitations des modèles pré-entraînés, telles que les hallucinations et l'obsolescence des connaissances. En connectant un LLM à une base de connaissances externe, le système peut interroger dynamiquement des documents propriétaires et formuler des réponses ancrées et vérifiables.

Page 2 : Stratégies de Chunking Avancées

Le découpage du texte (chunking) est une étape critique de tout pipeline RAG. Un mauvais découpage peut fragmenter le contexte sémantique ou fusionner des informations indépendantes. Les approches modernes privilégient un découpage respectant la structure logique des documents (paragraphe, sections, ou pages) avec un chevauchement (overlap) contrôlé pour préserver la continuité du flux informationnel.

Page 3 : Embeddings et Modèles Vectoriels

La vectorisation transforme les fragments de texte en vecteurs denses dans un espace vectoriel à haute dimension. Des modèles comme all-MiniLM-L6-v2 permettent de capturer la similarité sémantique entre les requêtes des utilisateurs et les documents indexés. Le choix du modèle d'embedding conditionne directement la qualité du rappel et la robustesse face aux reformulations complexes.

Page 4 : Indexation et Bases de Données Vectorielles

Les bases de données vectorielles, telles que ChromaDB ou FAISS, stockent les embeddings et permettent des recherches de plus proches voisins à grande échelle. L'utilisation de métriques de distance adaptées, comme la distance euclidienne ou la similarité cosinus, garantit une recherche performante. L'association de métadonnées riches (comme le numéro de page exact) est indispensable pour assurer la traçabilité des sources.

Page 5 : Stratégies de Récupération (Dense vs Hybride)

La recherche dense basée sur les embeddings excelle pour capturer le sens global des requêtes sémantiques. Cependant, elle peut échouer sur des mots-clés stricts ou des identifiants techniques. C'est pourquoi l'approche hybride, combinant recherche dense et recherche lexicale (BM25), s'impose pour maximiser la robustesse de la phase de récupération.

Page 6 : Ré-ordonnancement (Reranking) et Précision

Le reranking intervient après la récupération initiale pour affiner le classement des fragments avant l'envoi au LLM. Des modèles de type cross-encoder évaluent finement la pertinence croisée entre la requête et chaque chunk récupéré. Cette étape élimine le bruit, réduit la taille du contexte injecté et améliore drastiquement la précision globale de la réponse générée.

Page 7 : Architectures Agentiques et LangGraph

Les architectures RAG modernes évoluent vers des agents autonomes capables de planifier, d'exécuter des recherches itératives et d'évaluer la qualité des documents trouvés. Des frameworks comme LangGraph permettent de structurer ces flux complexes sous forme de graphes d'état décisionnels, autorisant des boucles de correction et de validation dynamique.

Page 8 : Optimisation des LLMs Locaux

L'exécution de LLMs en local via des outils comme Ollama (avec des modèles tels que DeepSeek-R1 ou Llama 3) garantit la confidentialité des données et l'indépendance vis-à-vis des API cloud. L'optimisation des paramètres d'inférence, de la température et de la taille du contexte permet d'atteindre un équilibre optimal entre vitesse de génération et rigueur logique.

Page 9 : Évaluation des Pipelines RAG

Mesurer la performance d'un système RAG nécessite des frameworks d'évaluation rigoureux comme RAGas. Les métriques clés incluent la pertinence du contexte récupéré, la fidélité de la réponse par rapport aux sources, et la pertinence de la réponse par rapport à la requête initiale. Ces indicateurs permettent d'identifier les goulets d'étranglement du pipeline.

Page 10 : Conclusion et Perspectives en Production

Le déploiement d'un système RAG en production requiert une surveillance continue de la qualité d'indexation, de la latence de récupération et de la pertinence des réponses. L'évolution constante des architectures agentiques et des modèles multimodaux ouvre la voie à des assistants documentaires toujours plus autonomes, précis et adaptés aux environnements métiers complexes.